银行年报问答知识库：一页结论

一、数据与处理
选取 10 家 A 股上市银行 2023 年年度报告，共 4,001 页。
用 pymupdf4llm 逐页转成 Markdown，表格按行列保留；
再按标题、段落和表格切块，每块带上公司、代码、年份、页码和章节。
最终得到 12,261 个可检索片段。PDF 不进入仓库，仓库只保留从东方财富公开公告接口下载年报的脚本。

二、检索与回答
检索采用 BM25 与向量检索的混合方案：jieba 分词后建 BM25，
BAAI/bge-small-zh-v1.5 生成 512 维归一化向量，按 45% / 55% 加权融合。
单公司问题先用“指标名 + 数值”的词法规则锁定原文，再取全局 top-8；
跨公司问题按公司分别检索，每家公司取 2 个片段，
避免上下文被一两家银行占满。大模型只负责组织语言，
关键数字必须带 [资料i]，页面同时列出公司、年份和页码供核对。

三、评测结果
按 8 个单公司事实题和 2 个跨公司比较题评测，答对 10 / 10
（准确率 100%；单公司 8/8，跨公司 2/2），平均响应 5.1 秒。
单公司题能直接命中“主要会计数据”“财务指标”等表；
跨公司题采用逐家公司检索后，10 家公司的指标能同时进入上下文。

四、错误与限制
本次评测未发现答错题；仍需注意：
· 部分单公司题的引用列表仍夹带少量无关页（如附注封面），高分出处已排在前面。
· 表格跨页时表头可能丢失，需按页码回看原PDF。
· 不同银行对净息差的表述不一致（净息差/净利息收益率），已做同义词扩展；其他指标仍需逐家核对口径。
· 大模型偶尔会把相邻行数字串行，关键数字必须以引用页复核。

五、结论
这个方案的价值不在“让模型背年报”，而在把答案钉在可核对的页面上：
检索负责找证据，模型负责归纳，引用负责可验证。
后续可以增加 reranker、按指标预抽取结构化表，以及继续完善
“净息差/净利息收益率”等同义表述的查询扩展。

附：代码、评测问题和逐题检索记录见仓库；页面截图见 screenshots/。